

Absatz 1: Dies ist ein Beispieltext, wie er in Word geschrieben und dann als PDF exportiert wird. Er enthält mehrere Sätze, um einen realistischen Textfluss zu erzeugen. Es gibt keine Bilder auf dieser Seite. Der Text sollte vollständig extrahierbar sein.

Absatz 2: Dies ist ein Beispieltext, wie er in Word geschrieben und dann als PDF exportiert wird. Er enthält mehrere Sätze, um einen realistischen Textfluss zu erzeugen. Es gibt keine Bilder auf dieser Seite. Der Text sollte vollständig extrahierbar sein.

Absatz 3: Dies ist ein Beispieltext, wie er in Word geschrieben und dann als PDF exportiert wird. Er enthält mehrere Sätze, um einen realistischen Textfluss zu erzeugen. Es gibt keine Bilder auf dieser Seite. Der Text sollte vollständig extrahierbar sein.

Absatz 4: Dies ist ein Beispieltext, wie er in Word geschrieben und dann als PDF exportiert wird. Er enthält mehrere Sätze, um einen realistischen Textfluss zu erzeugen. Es gibt keine Bilder auf dieser Seite. Der Text sollte vollständig extrahierbar sein.

Absatz 5: Dies ist ein Beispieltext, wie er in Word geschrieben und dann als PDF exportiert wird. Er enthält mehrere Sätze, um einen realistischen Textfluss zu erzeugen. Es gibt keine Bilder auf dieser Seite. Der Text sollte vollständig extrahierbar sein.

Absatz 6: Dies ist ein Beispieltext, wie er in Word geschrieben und dann als PDF exportiert wird. Er enthält mehrere Sätze, um einen realistischen Textfluss zu erzeugen. Es gibt keine Bilder auf dieser Seite. Der Text sollte vollständig extrahierbar sein.

Weiterer Absatz 1: Hier geht der Text weiter. In einem echten Dokument würde man hier Richtlinien, Tabellenbeschreibungen oder Erklärungen finden. Wieder kein Bild - nur Text. Ziel ist es, zu prüfen, ob der Text-Layer korrekt erhalten bleibt.


Weiterer Absatz 2: Hier geht der Text weiter. In einem echten Dokument würde man hier Richtlinien, Tabellenbeschreibungen oder Erklärungen finden. Wieder kein Bild - nur Text. Ziel ist es, zu prüfen, ob der Text-Layer korrekt erhalten bleibt.

Weiterer Absatz 3: Hier geht der Text weiter. In einem echten Dokument würde man hier Richtlinien, Tabellenbeschreibungen oder Erklärungen finden. Wieder kein Bild - nur Text. Ziel ist es, zu prüfen, ob der Text-Layer korrekt erhalten bleibt.

Weiterer Absatz 4: Hier geht der Text weiter. In einem echten Dokument würde man hier Richtlinien, Tabellenbeschreibungen oder Erklärungen finden. Wieder kein Bild - nur Text. Ziel ist es, zu prüfen, ob der Text-Layer korrekt erhalten bleibt.

Weiterer Absatz 5: Hier geht der Text weiter. In einem echten Dokument würde man hier Richtlinien, Tabellenbeschreibungen oder Erklärungen finden. Wieder kein Bild - nur Text. Ziel ist es, zu prüfen, ob der Text-Layer korrekt erhalten bleibt.

Erster Textabschnitt auf dieser Seite. Hier wird erklärt, worum es geht, bevor das Bild kommt. Der Text sollte extrahierbar bleiben, während das folgende Bild separat erkannt und optional per Vision-OCR verarbeitet werden kann.



Text nach dem Bild: Hier wird die Bedeutung des Diagramms erklärt. In einem realen Dokument stehen hier oft Erläuterungen, Hinweise oder Fortsetzungen des Textes. Dies testet die Fähigkeit, Text vor und nach einem Bild korrekt zu extrahieren und das Bild als separates Element zu behandeln.

Beispiel: Tabelle oder UI-Ausschnitt

1. Kunde
2. Betrag
3. Status
4. Datum




Abb. 2: Ergänzende Grafik / Screenshot

Dieser kurze Text steht unter dem Bild und beschreibt es. Auf dieser Seite dominiert das Bild, der Text ist nur ergänzend. Gut geeignet, um zu testen, ob ein 'nur Bild'-Seite korrekt als bildlastig erkannt wird.